

PgVector w PostgreSQL

Embeddings

- **Embeddings** to reprezentacje tekstu/obrazu/jednostek w postaci wektorów liczb rzeczywistych (np. 768 lub 1536 wymiarów), tak aby podobne znaczeniowo elementy były “blisko” siebie w przestrzeni wektorowej.
- **pgvector** to rozszerzenie do PostgreSQL, które dodaje natywny typ danych vector oraz operatory/metody indeksowania do efektywnego wyszukiwania podobieństwa między wektorami.

Kluczowe pojęcia

- Metryki podobieństwa/odległości:
 - **Cosinusowa**: $\leftrightarrow$ operator dla cosine distance ($1 - \text{cos_sim}$). Dobra do tekstu.
 - **Euklidesowa** (L2): $\leftrightarrow$ dla Euclidean distance.
 - **Inner product (IP) – iloczyn skalarny**: przydatna gdy embeddings są nieskalowane i chcemy maksymalizować iloczyn skalarny.

Metryka euklidesowa

- Metryka euklidesowa, znana również jako odległość euklidesowa, to najczęściej używana metoda mierzenia odległości między dwoma punktami w przestrzeni euklidesowej.
- W kontekście wektorów (takich jak te przechowywane w `pgvector`), odległość euklidesowa mierzy "prostą" odległość między końcami tych wektorów.

Metryka euklidesowa

- **Jak to działa?**

- Wyobraź sobie dwa punkty (lub wektory) w przestrzeni. Dla prostoty, zacznijmy od dwóch wymiarów (jak na kartce papieru):
- Punkt A ma współrzędne (x_1, y_1)
- Punkt B ma współrzędne (x_2, y_2)
- Odległość euklidesową między A i B obliczamy za pomocą wzoru, który jest rozszerzeniem twierdzenia Pitagorasa:

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Metryka euklidesowa

- **Intuicja**

- Im mniejsza odległość euklidesowa między dwoma wektorami, tym bardziej są one do siebie "podobne" w sensie geometrycznym.
- W kontekście pgvector i osadzeń, oznacza to, że wektory reprezentujące podobne obiekty (np. podobne teksty, obrazy) będą miały **mniejszą odległość euklidesową**.

Metryka euklidesowa

- **Kiedy używać metryki euklidesowej w pgvector?**
 - **Wielkość wektora ma znaczenie:** Jeśli długość wektora (jego norma) niesie ze sobą istotne informacje o danych, odległość euklidesowa będzie to uwzględniać.
 - **Chcesz znaleźć "najbliższych sąsiadów":** Jest to standardowa metryka do znajdowania elementów, które są geometrycznie blisko siebie.
 - **Dane są rozłożone w sposób, który dobrze pasuje do tej metryki:** Czasami inne metryki (jak podobieństwo cosinusowe) lepiej oddają relacje między danymi, ale euklidesowa jest dobrym punktem wyjścia.

Metryka euklidesowa

- W **pgvector** możesz użyć operatora $\leftarrow$ do obliczenia odległości euklidesowej (a dokładniej, kwadratu odległości euklidesowej, co jest często wystarczające do sortowania i jest szybsze do obliczenia, ponieważ pomija pierwiastek kwadratowy).

Metryka euklidesowa - warsztat

- Metryka `euklidesowa.sql`

Metryka cosinusowa

- Metryka cosinusowa to miara podobieństwa między dwoma wektorami w przestrzeni wielowymiarowej. Zamiast mierzyć odległość między wektorami (jak np. odległość euklidesowa), mierzy ona kąt między nimi. Im mniejszy kąt, tym większe podobieństwo.
- **Podobnie jak w L2 -> mniejsza metryka cosinusowa = większe prawdopodobieństwo**

Metryka cosinusowa

- **Jak to działa?**
 - Wyobraź sobie dwa wektory wychodzące z początku układu współrzędnych. Metryka cosinusowa oblicza cosinus kąta między tymi wektorami. Wartość cosinusa kąta:
 - **1** oznacza, że wektory są identyczne (kąt 0 stopni).
 - **0** oznacza, że wektory są prostopadłe (kąt 90 stopni), czyli nie mają ze sobą nic wspólnego.
 - **-1** oznacza, że wektory są dokładnie przeciwne (kąt 180 stopni).
 - W kontekście pgvector i osadzania (embeddings), wektory reprezentują cechy obiektów (np. tekstów, obrazów). Jeśli dwa wektory są do siebie podobne (mają mały kąt między sobą), oznacza to, że obiekty, które reprezentują, są również podobne.

Metryka cosinusowa

- **Dlaczego jest przydatna w pgvector?**
- W pgvector, gdzie przechowujesz wektory osadzeń (embeddings), metryka cosinusowa jest często używana do wyszukiwania podobnych elementów.
- Na przykład, jeśli masz bazę danych z wektorami reprezentującymi opisy produktów, możesz użyć metryki cosinusowej, aby znaleźć produkty o podobnych opisach do zapytania użytkownika.

Metryka cosinusowa

- Dlaczego jest przydatna w pgvector?
- Kluczową zaletą metryki cosinusowej jest to, **że jest ona niezależna od długości wektorów.**
- Oznacza to, że jeśli dwa wektory mają ten sam kierunek, ale jeden jest dłuższy od drugiego, ich podobieństwo cosinusowe będzie nadal wysokie.
- Jest to szczególnie ważne w przypadku osadzeń(embeddings), gdzie długość wektora może nie zawsze odzwierciedlać znaczenie, ale kierunek wektora jest kluczowy dla reprezentacji semantycznej.

Metryka cosinusowa - warsztat

- Metryka cosinusowa.sql

Metryka INNER PRODUCT (IP)

- **Inner Product, czyli iloczyn skalarny (często oznaczany jako IP),** to jedna z metryk używanych do mierzenia podobieństwa między wektorami.
- W kontekście baz danych wektorowych, takich jak pgvector, służy do określania, jak bardzo dwa wektory są do siebie podobne.
- Matematycznie to suma iloczynów:

$$A \cdot B = \sum_{i=1}^n a_i b_i = a_1 b_1 + a_2 b_2 + \dots + a_n b_n$$

Metryka IP

- **Jak działa Inner Product jako metryka podobieństwa?**
 - W przypadku Inner Product, **większa wartość iloczynu skalarnego oznacza większe podobieństwo.**
 - **Wektory w tym samym kierunku:** Jeśli dwa wektory wskazują w tym samym kierunku (są do siebie bardzo podobne), ich iloczyn skalarny będzie duży i pozytywny.

Metryka IP

- **Jak działa Inner Product jako metryka podobieństwa?**
 - **Wektory prostopadłe:** Jeśli wektory są prostopadłe (nie mają ze sobą nic wspólnego), ich iloczyn skalarny będzie bliski zeru.
 - **Wektory w przeciwnych kierunkach:** Jeśli wektory wskazują w przeciwnych kierunkach (są do siebie bardzo niepodobne), ich iloczyn skalarny będzie duży i negatywny.

Metryka IP - normalizacja

- Ważne jest, aby pamiętać, że Inner Product jest wrażliwy na długość wektorów (ich normę). Dłuższe wektory będą miały tendencję do większych iloczynów skalarnych, nawet jeśli ich kierunek jest mniej podobny.
- Dlatego też, aby Inner Product działał efektywnie jako metryka podobieństwa, **często normalizuje się wektory do jednostkowej długości (normy 1)**. Kiedy wektory są znormalizowane, Inner Product staje się równoważny z **cosinusowym podobieństwem**
- W pgvector, jeśli używasz operatora `<#>` (dla Inner Product), a Twoje wektory są znormalizowane, to efektywnie mierzysz podobieństwo cosinusowe.

Metryka IP

-

kiedy używać

- **Wektory są znormalizowane:** Wtedy działa jak podobieństwo cosinusowe, które jest bardzo popularne w wyszukiwaniu semantycznym (np. w modelach językowych, gdzie wektory reprezentują znaczenie słów lub zdań).
- **Chcesz, aby długość wektora miała znaczenie:** W niektórych przypadkach długość wektora może kodować dodatkowe informacje (np. ważność lub intensywność). Wtedy nienormalizowany Inner Product może być odpowiedni.

Metryka IP

- Metryka INNER PRODUCT.sql